EquiTech — diagnostic de rémunération

Distinguer écart brut, composition des postes et association ajustée.

Analyse reproductible dans Jupyter ; présentation modifiable.

Données fictives : aucune mission réelle ni effet causal démontré.

Question et méthode

Distinguer écart brut, composition des postes et association ajustée.

Contrôler les clés, les doublons et les valeurs invalides avant les agrégations.

Lire les unités et les hypothèses du notebook avant de comparer les résultats.

Qualité des données

{'table': 'rh', 'brut': 12050, 'doublons': 50, 'rejets': 30, 'propre': 11970}

Indicateurs recalculés

effectif : 11970

ecart brut : 0.0413

ic95 brut bas : 0.0307

ic95 brut haut : 0.0519

ecart ajuste descriptif : 0.0359

ecart ajuste bas : 0.0325

ecart ajuste haut : 0.0393

Indicateurs recalculés

r2 : 0.8974

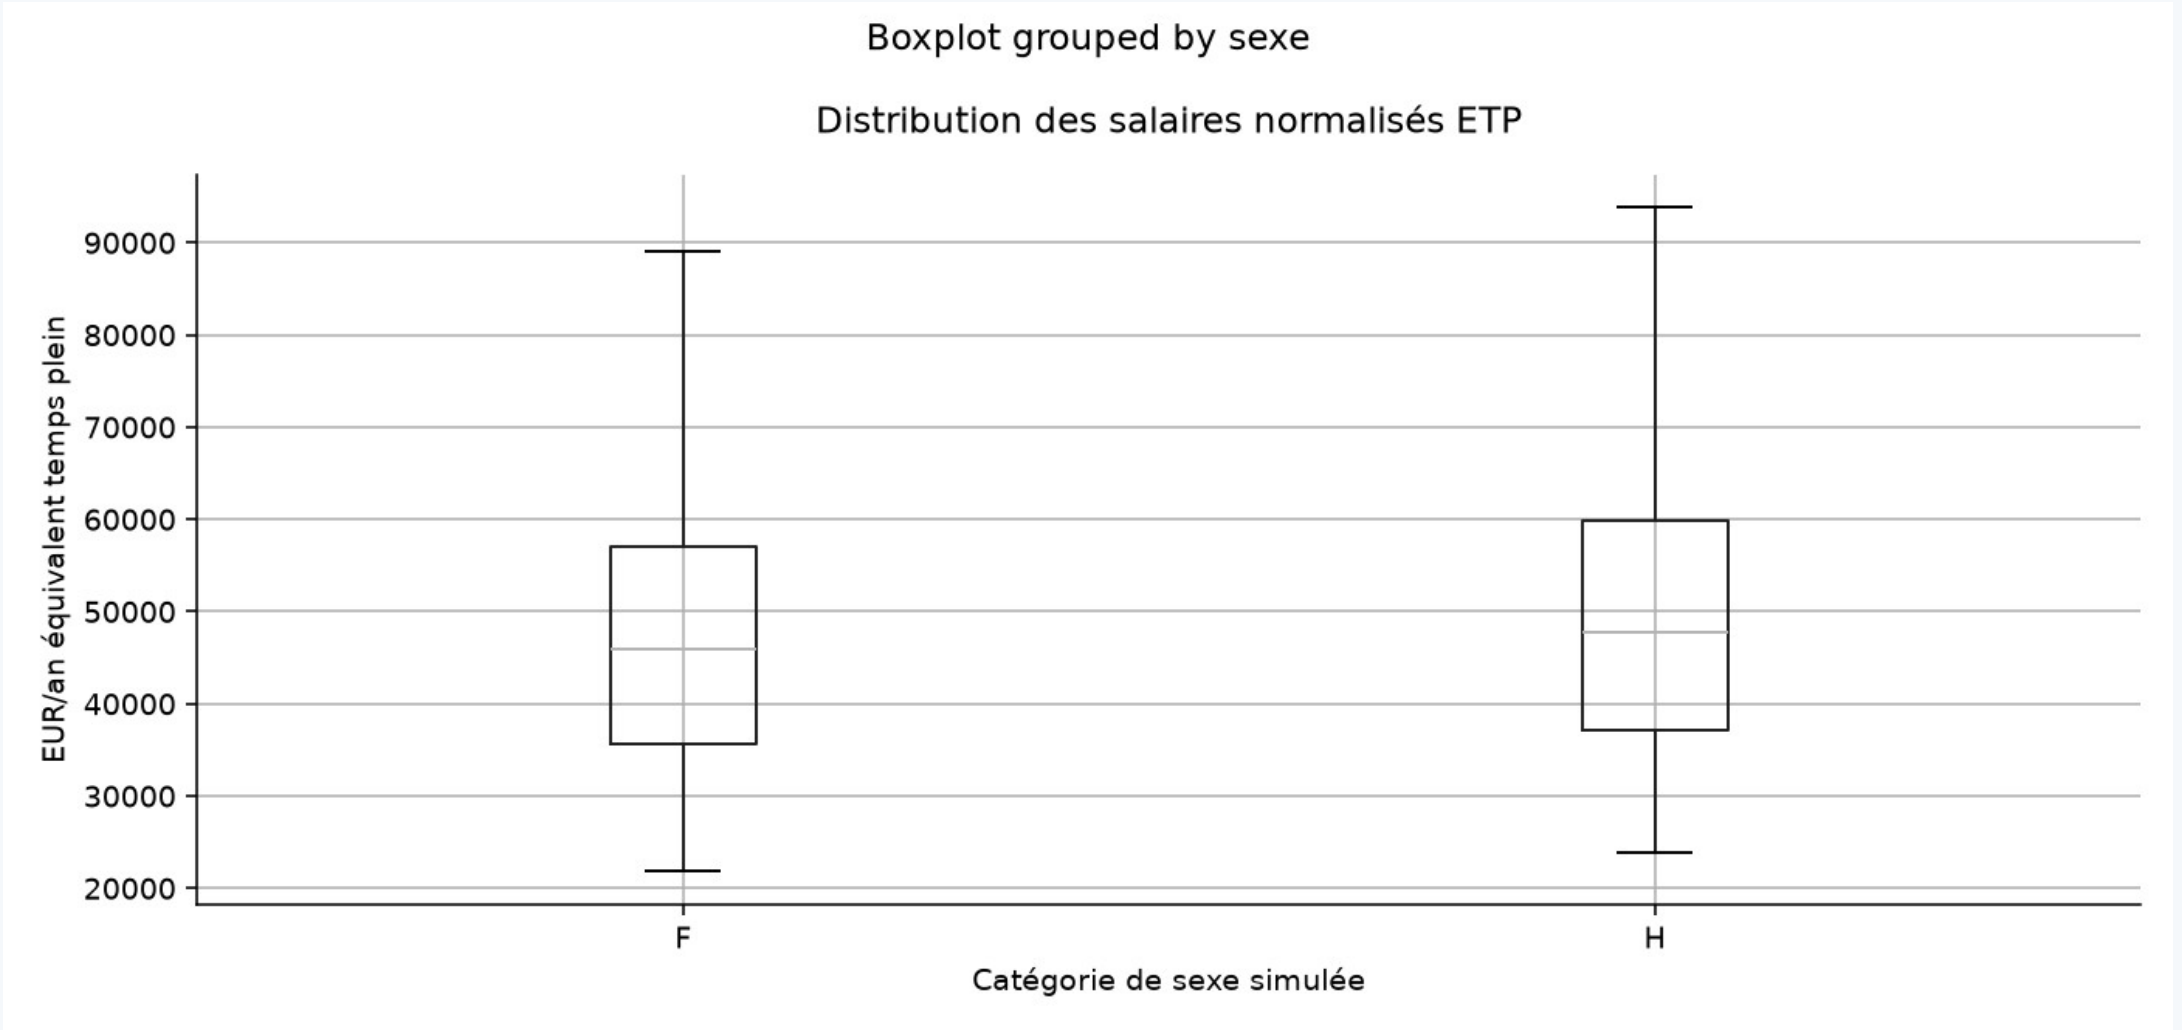
groupes masques : 5

Résultats à retenir

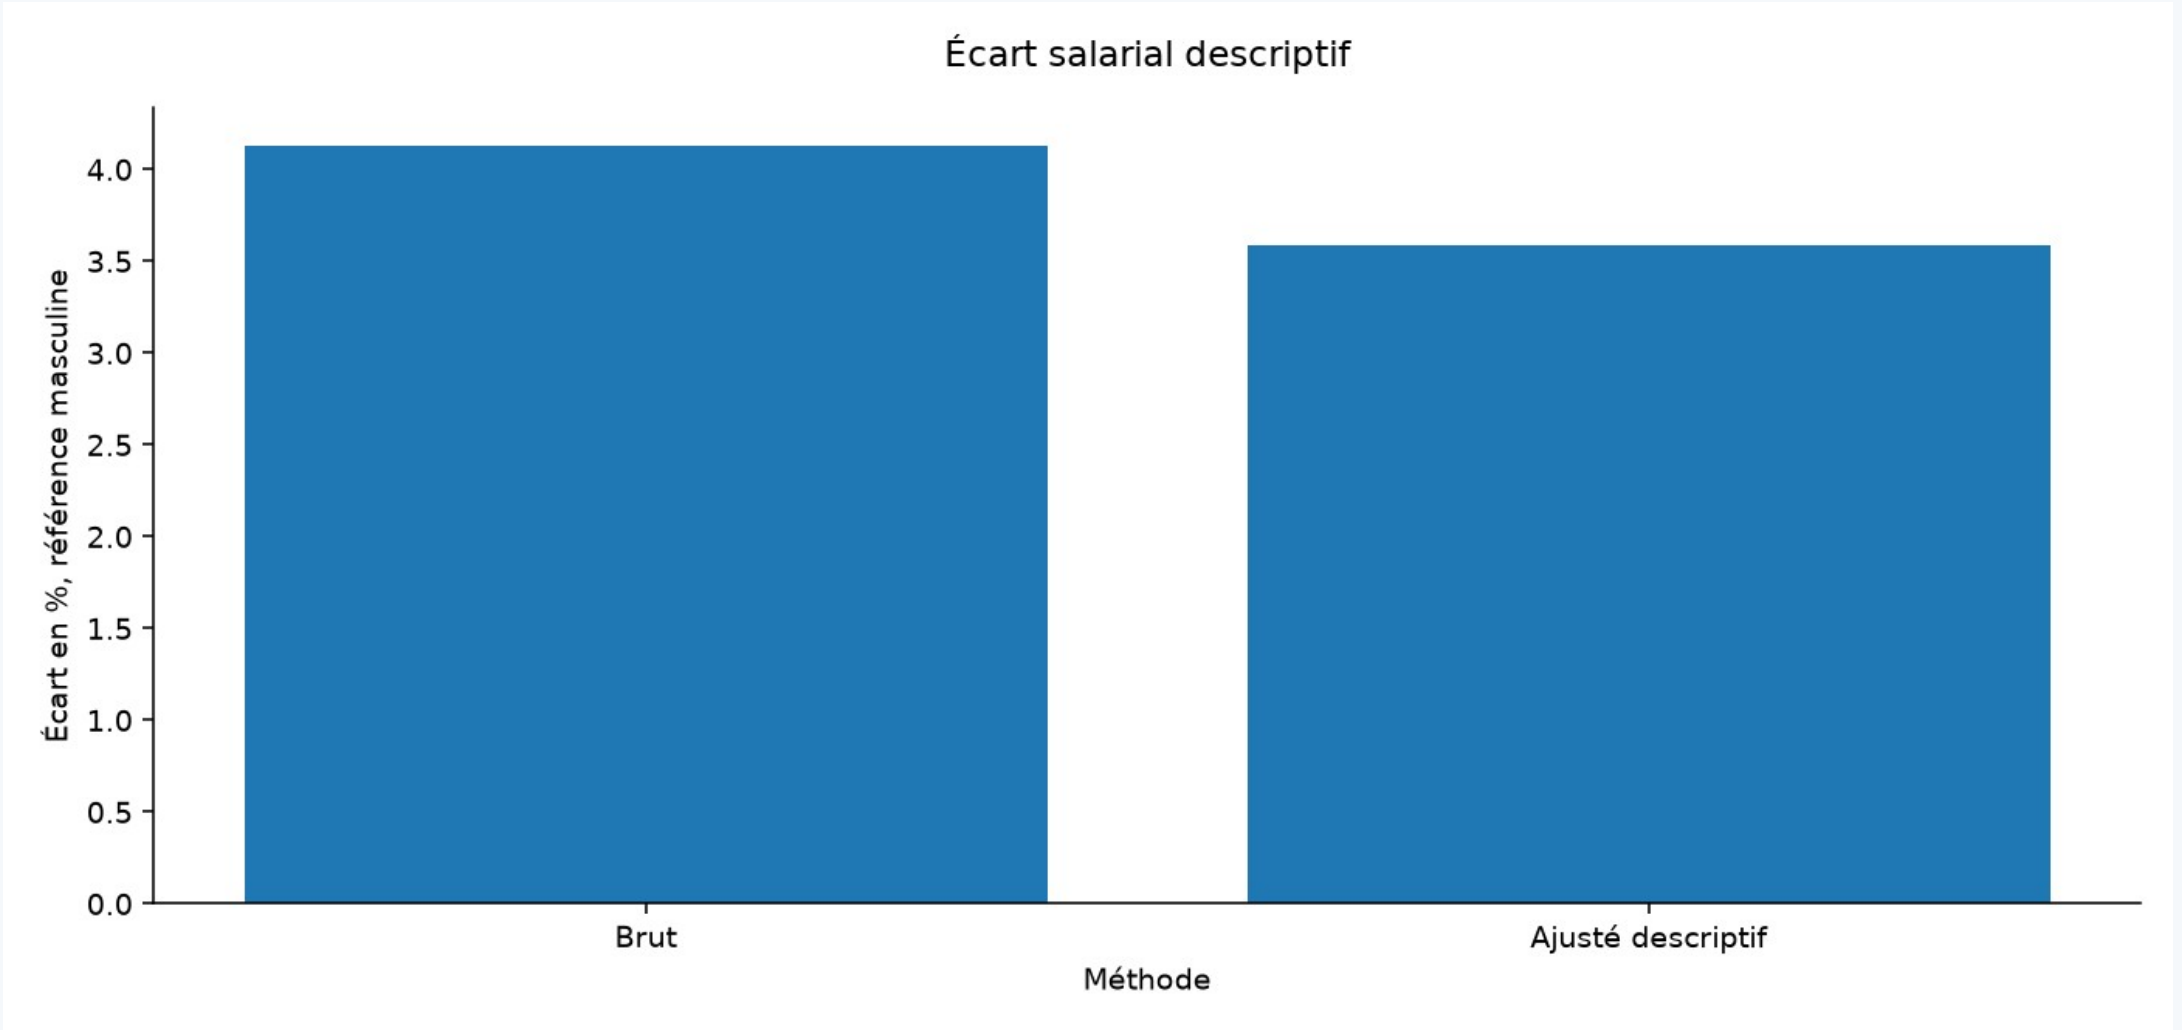
Écart brut ETP : 4.13 % ; IC bootstrap [3.07 ; 5.19] %.

Écart ajusté descriptif : 3.59 %, erreurs robustes HC3.

Salaires etp



Ecarts brut ajuste



4. Rendre les rémunérations comparables

Le salaire versé correspond au temps contractuel. Une personne à 50 % et une personne à temps plein ne sont pas directement comparables sur ce montant annuel. Le salaire ETP est défini par salaire_annuel_verse / quotite ; une quotité nulle ou hors intervalle rend le calcul invalide.

L'écart calculé directement sur le salaire versé vaut 4,55 % ; après normalisation ETP, il vaut 4,13 %. Cette différence illustre l'importance de la définition, sans fournir une explication causale de la répartition des temps partiels.

5. Lire l’écart brut et son incertitude

L’écart retenu est 1 − moyenne_F / moyenne_H, avec H comme référence au dénominateur. Il vaut 4,13 %. Une valeur positive signifie une moyenne F inférieure dans cette convention ; inverser le dénominateur ne produit pas le même pourcentage en valeur absolue.

Le bootstrap rééchantillonne séparément les deux groupes 500 fois. Les quantiles 2,5 % et 97,5 % donnent [3,07 % ; 5,19 %]. Cet intervalle décrit la variabilité de cette procédure sur la simulation, pas l’ensemble des erreurs de mesure ou de sélection d’un cas réel.

6. Comparer standardisation et régression ajustée

Une standardisation simple applique à chaque groupe les mêmes poids de niveaux, ceux de la population totale. L'écart obtenu est 3,64 %. Il contrôle uniquement la composition des niveaux ; il ne remplace pas un ajustement sur toutes les caractéristiques observées.

La régression utilise log(salaire_etp) avec sexe, niveau, métier, site, ancienneté et âge. Les catégories sont encodées avec une référence et les erreurs-types sont robustes HC3. La comparaison ajustée est une association conditionnelle au modèle spécifié, sans mécanisme causal identifié.

7. Diffuser des agrégats sans surestimer la protection

Les croisements site × métier × niveau × sexe produisent 165 cellules ; 5 sont sous dix salariés et n’affichent ni effectif ni rémunération. Les mesures correspondantes restent non observées dans l’export public, plutôt que remplacées par zéro.

Masquer une seule petite cellule peut être insuffisant si un total de ligne ou une autre vue permet de la retrouver par soustraction. Une stratégie réelle demanderait des contrôles de complémentarité entre tableaux et, selon le contexte, une suppression secondaire ou une agrégation plus large.

8. Décider des vérifications complémentaires

Le bon usage des résultats est de définir un audit complémentaire : vérifier la comparabilité des fonctions, analyser les trajectoires d'accès aux niveaux, intégrer les composantes de rémunération et documenter le périmètre temporel.

Aucune action individuelle n'est recommandée à partir d'un coefficient global. Il faut distinguer une différence moyenne observée d'une situation individuelle, puis vérifier les données et les règles de comparaison avant toute décision.

Actions proposées

Examiner les distributions par métier et niveau avant interprétation.

Appliquer contrôle d’accès et diffusion agrégée sur de vraies données.

Limites et prochaines étapes

Données fictives ; catégories de sexe simplifiées.

Ce diagnostic n’est ni l’index légal français ni une preuve de discrimination.

Pseudonymisation et seuil de 10 ne garantissent pas anonymisation ou conformité RGPD ; données individuelles publiables ici uniquement car synthétiques.

Workflow KNIME à reconstruire ; référence exécutée en Python.

Adapter les hypothèses et valider sur des données réelles avant toute décision.